《大数据应用》 课 程 论 文

(2025-2026 学年第一学期)

基于 Apriori 算法的购物篮关联规则挖掘与应用

学生姓名：张弘

提交日期： 2025 年 12 月 28 日　　学生签名：张弘

学　　号	202367400261	座位编号	32
学　　院	数学学院	专业班级	数学类（强基计划班）
课程名称	大数据应用	任课教师	张威
教师评语：			
本论文成绩评定： _____分			

目 录

1 绪论 **1**

1.1 研究背景与意义 1

1.2 数据集介绍 2

2 相关理论与技术 **2**

2.1 关联规则挖掘基本概念 2

2.2 评价指标 3

2.3 Apriori 算法 4

2.4 技术实现 4

3 数据预处理与探索性分析 **5**

3.1 数据加载与清洗 5

3.2 探索性数据分析 6

3.3 交易-商品矩阵构建 9

4 关联规则挖掘实验 **9**

4.1 实验参数设置 9

4.2 频繁项集与关联规则挖掘 10

4.3 Top 关联规则分析 11

4.4 规则质量可视化 11

4.5 提升度含义解读 13

5 业务解读与应用建议 **14**

5.1 高价值规则业务解读 14

5.2 促销策略设计 15

5.3 实施建议 15

6 结论与展望 **16**

6.1 研究总结 16

6.2 主要结论与研究局限 17

6.3 未来展望 17

参考文献 **19**

基于 Apriori 算法的购物篮关联规则挖掘与应用

张弘

摘要：购物篮分析是数据挖掘领域的经典应用，通过挖掘顾客购买行为中的关联规则，可帮助零售企业制定精准营销策略。本文以 UCI Online Retail 数据集为研究对象，运用 Apriori 算法对英国某在线零售商的 541,909 条交易记录进行关联规则挖掘。研究首先对原始数据进行预处理，包括缺失值处理、异常订单剔除等，最终保留 530,104 条有效记录，涉及 19,960 笔订单和 4,026 种商品。通过设置最小支持度 0.015、最小置信度 0.4、最小提升度 3.0 的阈值参数，成功挖掘出 709 个频繁项集和 295 条强关联规则。实验结果表明，同系列商品存在极强关联，其中 REGENCY 茶盘组合的提升度高达 37.55，置信度达 83.73%，表明顾客具有显著的成套购买倾向。基于挖掘结果，本文提出了捆绑销售、智能推荐和场景化陈列三类营销策略，为零售企业精准营销提供了数据支撑。

关键词：购物篮分析；关联规则；Apriori 算法；数据挖掘；零售营销

1 绪论

1.1 研究背景与意义

随着电子商务和零售行业的快速发展，企业积累了海量的交易数据。如何从这些数据中挖掘有价值的信息，发现顾客的购买规律，已成为企业获取竞争优势的关键因素。购物篮分析（Market Basket Analysis，MBA）作为数据挖掘领域的经典应用，通过分析顾客的购买行为，发现商品之间的关联关系，为企业的营销决策、库存管理、商品陈列等提供科学依据 [1]。

购物篮分析的核心思想是：顾客在一次购物过程中购买的商品之间往往存在某种关联关系。例如，购买面包的顾客很可能同时购买牛奶，购买尿布的父亲可能会顺便购买啤酒。这种隐藏在交易数据中的规律，如果能够被有效挖掘和利用，将为零售企业带来显著的商业价值：一是通过捆绑销售、交叉促销提高销售额；二是优化商品陈列引导连带购买；三是预测关联商品销售趋势优化库存；四是基于历史记录实现个性化推荐。

在技术层面，1993 年 Agrawal 等人提出的 Apriori 算法 [2] 成为关联规则挖掘领域的里程碑。该算法基于” 频繁项集的所有非空子集也必须是频繁的” 这一先验性质，有效减少了候选项集的搜索空间，使得大规模数据的关联规则挖掘成为可能。本研究旨在利

用 Apriori 算法对真实零售交易数据进行分析，挖掘商品关联规则，并将结果转化为可行的营销策略建议。

1.2 数据集介绍

本研究使用 UCI Machine Learning Repository 提供的"Online Retail" 数据集 [3]，该数据集记录了英国一家在线零售商在 2010 年 12 月至 2011 年 12 月期间的全部交易数据，主要销售英式礼品类商品，客户群体以批发商为主。数据集基本信息如表1所示。

Table 1: Online Retail 数据集基本信息

属性	描述	属性	描述
数据来源	UCI Repository	记录数量	541,909 条
时间范围	2010.12 - 2011.12	涉及国家	38 个

数据集包含 8 个字段，各字段说明如表2所示：

Table 2: 数据集字段说明

字段名	类型	说明
InvoiceNo	String	发票编号，C 开头表示取消订单
StockCode	String	商品编码
Description	String	商品描述
Quantity	Integer	购买数量
InvoiceDate	DateTime	交易日期时间
UnitPrice	Float	单价（英镑）
CustomerID	Float	客户编号
Country	String	客户所在国家

2 相关理论与技术

2.1 关联规则挖掘基本概念

关联规则挖掘是数据挖掘领域的重要研究方向，目标是从大规模数据集中发现变量之间的关联关系 [4]。在零售领域通常被称为" 购物篮分析"，用于发现顾客购买行为中

商品之间的关联模式。

设 $I = \{i_1, i_2, \ldots, i_m\}$ 为所有商品的集合，I 的任意子集称为项集，包含 k 个商品的项集称为 k-项集。一次购物交易记录称为事务 T（$T \subseteq I$），所有事务的集合称为事务数据库 D。关联规则是形如 $X \Rightarrow Y$ 的蕴含式，其中 $X, Y \subset I$ 且 $X \cap Y = \emptyset$，X 称为前项，Y 称为后项。

关联规则挖掘问题可形式化为：给定事务数据库 D 和最小支持度阈值 min_sup、最小置信度阈值 min_conf，找出所有满足条件的关联规则：

$$\{X \Rightarrow Y \mid support(X \Rightarrow Y) \geq min_sup \ \wedge \ confidence(X \Rightarrow Y) \geq min_conf\} \tag{1}$$

该问题分解为两个子问题：频繁项集挖掘（找出支持度不小于 min_sup 的项集）和规则生成（对每个频繁项集生成满足置信度要求的规则）。

2.2 评价指标

关联规则的质量用三个核心指标衡量。**支持度**表示规则在数据库中的频繁程度，定义为同时包含 X 和 Y 的事务占比：

$$support(X \Rightarrow Y) = P(X \cup Y) = \frac{|\{T \in D \mid X \cup Y \subseteq T\}|}{|D|} \tag{2}$$

置信度表示购买 X 的顾客中同时购买 Y 的条件概率：

$$confidence(X \Rightarrow Y) = P(Y|X) = \frac{support(X \cup Y)}{support(X)} \tag{3}$$

提升度衡量规则的实际关联强度，即关联购买概率相比随机购买的提升倍数：

$$lift(X \Rightarrow Y) = \frac{confidence(X \Rightarrow Y)}{support(Y)} = \frac{P(X \cup Y)}{P(X) \cdot P(Y)} \tag{4}$$

提升度大于 1 表示正相关，等于 1 表示独立，小于 1 表示负相关。例如，若商品 B 出现率为 5%，规则 $A \Rightarrow B$ 置信度为 50%，则提升度为 $50\%/5\% = 10$，表示购买 A 的顾客购买 B 的概率是随机顾客的 10 倍。本研究采用的阈值参数如表3所示。

Table 3: 本研究采用的阈值参数

指标	阈值	说明
最小支持度	0.015	至少出现在 1.5% 的交易中（≥299 笔）
最小置信度	0.4	条件概率至少为 40%
最小提升度	3.0	关联购买概率至少是随机购买的 3 倍

2.3 Apriori 算法

Apriori 算法由 Agrawal 和 Srikant 于 1994 年提出 [2]，其核心思想基于 Apriori 性质：若一个项集是频繁的，则其所有非空子集也必须是频繁的；反之，若一个项集是非频繁的，则其所有超集也必须是非频繁的。基于此性质，算法采用逐层搜索的迭代策略，从频繁 1-项集开始，逐步生成更长的候选项集并剪枝，直到无法生成新的候选项集为止。算法流程如算法1所示。

Algorithm 1 Apriori 算法

输入: 事务数据库 D，最小支持度 min_sup

输出: 所有频繁项集 L

$L_1 \leftarrow$ 频繁 1-项集
for $k = 2$; $L_{k-1} \neq \emptyset$; k++ **do**
  $C_k \leftarrow$ 由 L_{k-1} 连接生成候选 k-项集
  扫描 D 统计 C_k 中各项集的支持度
  $L_k \leftarrow$ 满足 min_sup 的候选项集
end for
return $L = \bigcup_k L_k$

由频繁项集生成关联规则时，对每个频繁项集 l 枚举所有 $(l - s) \Rightarrow s$ 形式的规则（$s \subset l$），保留置信度满足阈值的规则。

2.4 技术实现

本研究基于 Python 开发，核心代码如下：

```python
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori, association_rules
```

```python

# One-Hot编码
te = TransactionEncoder()
df_encoded = pd.DataFrame(te.fit_transform(transactions),
                          columns=te.columns_)
# 频繁项集挖掘
frequent_itemsets = apriori(df_encoded, min_support=0.015,
                            use_colnames=True)
# 关联规则生成与筛选
rules = association_rules(frequent_itemsets, metric="confidence",
                          min_threshold=0.4)
strong_rules = rules[rules['lift'] >= 3.0]
```

Listing 1: Apriori 关联规则挖掘核心代码

3 数据预处理与探索性分析

3.1 数据加载与清洗

使用 pandas 库读取原始 Excel 数据后，首先进行基本结构检查。原始数据集包含 541,909 条交易记录和 8 个字段，时间跨度从 2010 年 12 月至 2011 年 12 月。每条记录代表一次交易中的一个商品项，同一笔订单（相同 InvoiceNo）包含多条记录，这种结构符合购物篮分析的典型场景。数据样本如表4所示。

Table 4: 原始数据样本

InvoiceNo	StockCode	Description	Qty	Price
536365	85123A	WHITE HANGING HEART T-LIGHT HOLDER	6	2.55
536365	71053	WHITE METAL LANTERN	6	3.39
536366	22633	HAND WARMER UNION JACK	6	1.85

缺失值分析显示, Description 字段有 1,454 条缺失（0.27%), CustomerID 字段有 135,080 条缺失（24.93%）。对于购物篮分析，Description 是识别商品的关键信息，缺失记录需删除；而 CustomerID 的缺失不影响分析目标，因为本研究关注订单内商品关联而非顾客行为。

针对数据问题，设计四步清洗策略：删除缺失 Description/InvoiceNo 的记录（-1,454 条）；删除以"C" 开头的取消订单（-9,288 条）；删除负数量记录（-474 条）；删除异常单价记录（-589 条）。清洗过程汇总如表5所示。

Table 5: 数据清洗过程汇总

清洗操作	清洗前	清洗后	删除量
删除缺失 Description/InvoiceNo	541,909	540,455	1,454
删除取消订单 (C 开头)	540,455	531,167	9,288
删除负数量记录	531,167	530,693	474
删除异常单价记录	530,693	530,104	589
总计	**541,909**	**530,104**	**11,805**

经过清洗，最终保留 530,104 条有效记录，数据保留率达 97.8%，表明原始数据质量总体良好。

3.2 探索性数据分析

清洗后数据集的基础统计显示：有效记录 530,104 条，唯一订单 19,960 笔，唯一商品 4,026 种，唯一客户 4,338 位，涉及 38 个国家，总交易金额 £10,666,684.54。平均每笔订单包含约 26.56 个商品项，显著高于普通 B2C 零售，说明客户以批发商为主。数值型变量统计如表6所示，数据呈现显著右偏特征——均值远大于中位数，存在大量小额订单和少量大额批发订单。

Table 6: 数值型变量描述性统计

统计量	Quantity	UnitPrice(£)	TotalPrice(£)
均值	10.54	3.91	20.12
中位数	3	2.08	9.90
最大值	80,995	13,541.33	168,469.60

时间维度分析揭示了明显的季节性特征。从月度趋势（图1）可见，2011 年 9 月至 11 月订单量显著增长，与圣诞节前采购旺季吻合。每周分布显示工作日订单量明显高于周末，周六不营业，周四为订单高峰。每小时分布集中在上午 9 点至下午 5 点，高峰在 10 点至 15 点，进一步印证 B2B 业务特点。

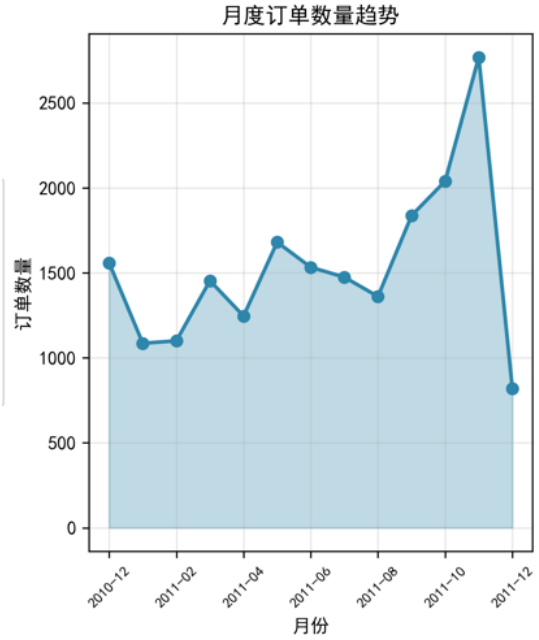

Figure 1: 月度订单数量趋势

地理维度分析（图2）显示，英国本土市场贡献超过 82% 销售额，其他重要市场包括德国、法国、爱尔兰等欧洲国家。这种地理集中度意味着挖掘出的关联规则主要反映英国市场消费特征。

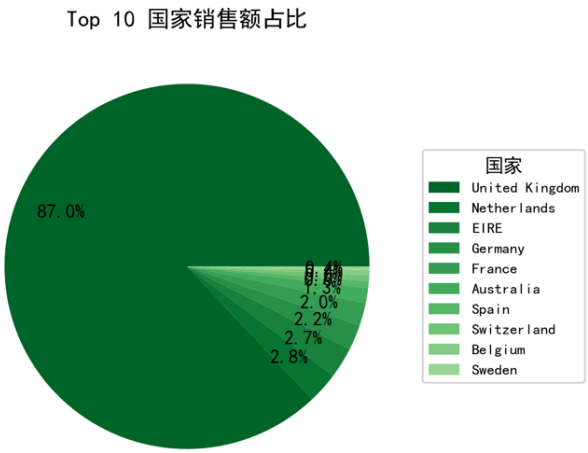

Figure 2: Top 10 国家销售额占比

商品维度分析（图3）显示，热销商品以装饰类为主，包括烛台、手提袋、蛋糕架等，符合礼品零售商定位。多个商品属于同一系列（如 REGENCY 茶具、RETROSPOT 手提袋），暗示系列商品间可能存在强关联购买倾向。

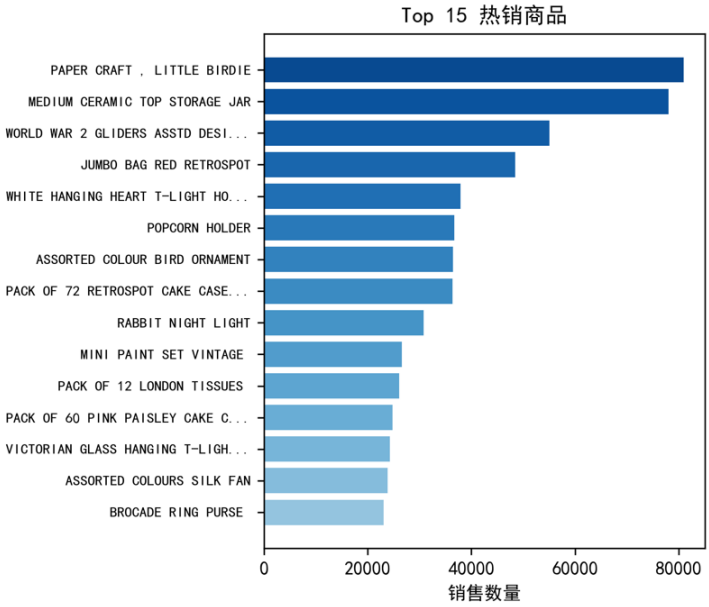

Figure 3: Top 15 热销商品

订单规模分布（图4）呈典型长尾特征：多数订单包含 10 件以内商品，但存在包含数百甚至上千件的大额批发订单（最大 1,114 件）。较大的订单规模为发现更多商品关联组合提供了可能。

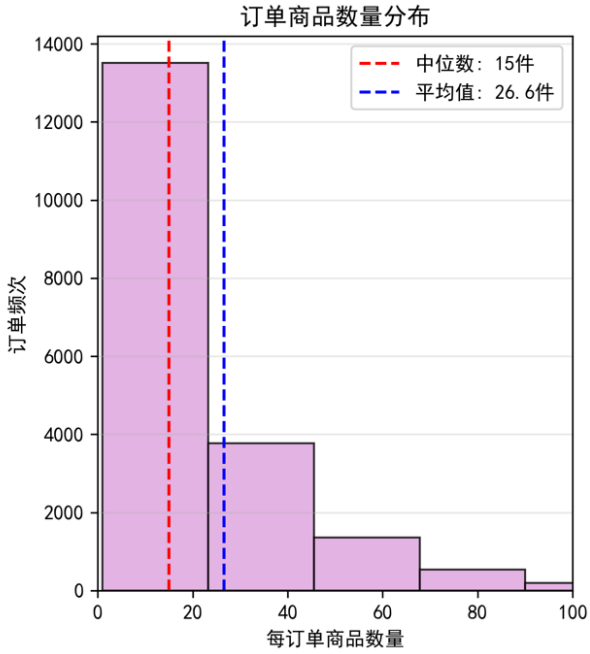

Figure 4: 订单商品数量分布

3.3 交易-商品矩阵构建

Apriori 算法要求输入交易-商品布尔矩阵，需将原始明细数据进行转换。首先将同一订单的所有商品聚合为列表，530,104 条明细记录转换为 19,960 个购物篮；然后使用 TransactionEncoder 进行 One-Hot 编码，得到 $19,960 \times 4,026$ 的布尔矩阵。矩阵统计如表7所示。

Table 7: One-Hot 编码矩阵统计

指标	数值	指标	数值
矩阵行数	19,960	矩阵列数	4,026
总元素数	80,358,960	非零元素	529,907
		稀疏度	99.35%

矩阵稀疏度高达 99.35%，这是购物篮数据的典型特征——每个顾客只购买全部商品中极小部分。高频商品统计显示，最热门商品”WHITE HANGING HEART T-LIGHT HOLDER” 出现在 11.30% 的交易中，即使是最热门商品出现率也仅略高于 10%，这解释了关联规则支持度通常较低的原因。

4 关联规则挖掘实验

4.1 实验参数设置

Apriori 算法效果取决于三个关键参数，需在规则数量与质量间取得平衡。最小支持度考虑数据规模（19,960 笔交易）和稀疏度（99.35%），设为 0.015（1.5%），即商品组合至少出现在 299 笔交易中。最小置信度设为 0.4（40%），保证规则的预测可靠性。最小提升度设为 3.0，确保关联购买概率至少是随机购买的 3 倍，过滤虚假关联。最大项集长度限制为 3，因为更长项集支持度急剧下降且 3-项集已满足多数商业场景需求。参数设置如表8所示。

Table 8: 实验参数设置

参数	取值	说明
最小支持度	0.015	至少出现在 299 笔交易中
最小置信度	0.4	条件概率至少 40%
最小提升度	3.0	关联强度至少 3 倍
最大项集长度	3	最多挖掘 3-项集

4.2 频繁项集与关联规则挖掘

使用 mlxtend 库执行 Apriori 算法，核心代码如下：

```
from mlxtend.frequent_patterns import apriori, association_rules

# 频繁项集挖掘
frequent_itemsets = apriori(df_onehot, min_support=0.015,
                            use_colnames=True, max_len=3)
# 关联规则生成与筛选
rules = association_rules(frequent_itemsets, metric="confidence",
                          min_threshold=0.4)
strong_rules = rules[rules['lift'] >= 3.0].sort_values('lift',
    ascending=False)
```

Listing 2: Apriori 关联规则挖掘代码

频繁项集挖掘结果显示，共发现 709 个频繁项集：1-项集 471 个（66.4%）、2-项集 210 个（29.6%）、3-项集 28 个（4.0%）。项集数量随长度增加急剧减少，符合 Apriori 性质预期。在 4,026 种商品中，约 11.7% 满足最小支持度要求。

基于频繁项集生成关联规则，统计结果如表9所示。共得到 295 条强关联规则，涉及 109 种不同商品。规则平均提升度达 11.57，最高 37.55，表明存在极强商品关联。规则类别分布显示收纳类（46.8%）和午餐袋类（21.4%）占比最高，反映产品线特点；茶具类虽规则数量少（12.2%）但关联强度最高。

Table 9: 关联规则统计结果

指标	数值	指标	数值
强规则数量	295	涉及商品数	109
平均支持度	0.0201	平均置信度	55.67%
平均提升度	11.57	最高提升度	37.55

4.3 Top 关联规则分析

按提升度排序的 Top 10 关联规则如表10所示。分析发现三个规律：（1）双向规则成对出现，如”GREEN→ROSES” 和”ROSES→GREEN” 支持度和提升度相同，但置信度不同，应选择置信度更高方向作为推荐基础；（2）同系列商品关联最强，REGENCY 茶盘（提升度 37.55）、PLAYHOUSE 玩具（33.87）、圣诞装饰（28.12）等系列商品体现” 配套效应”；（3）功能互补商品关联显著，如纸杯与纸盘（30.97）在派对场景中一起使用。

Table 10: Top 10 关联规则

名	规则	支持度	置信度	提升度
1	TEA PLATE GREEN → TEA PLATE ROSES	0.0160	83.73%	37.55
2	TEA PLATE ROSES → TEA PLATE GREEN	0.0160	71.69%	37.55
3	PLAYHOUSE BEDROOM → PLAYHOUSE KITCHEN	0.0157	74.00%	33.87
4	PLAYHOUSE KITCHEN → PLAYHOUSE BEDROOM	0.0157	71.79%	33.87
5	PAPER CUPS → PAPER PLATES	0.0175	81.78%	30.97
6	PAPER PLATES → PAPER CUPS	0.0175	66.41%	30.97
7	MARSHMALLOWS → DOLLY MIX DESIGN	0.0175	78.08%	29.57
8	DOLLY MIX → MARSHMALLOWS DESIGN	0.0175	66.22%	29.57
9	STAR CHRISTMAS → HEART CHRISTMAS	0.0194	75.78%	28.12
10	HEART CHRISTMAS → STAR CHRISTMAS	0.0194	72.12%	28.12

4.4 规则质量可视化

图5展示规则在支持度-置信度空间的分布，点的颜色和大小反映提升度。规则主要分布在支持度 1.5%-4%、置信度 40%-90% 区域，右上角（高支持度 + 高置信度）规则最具商业价值。图6以柱状图展示 Top 15 规则提升度排名，前两位（REGENCY 茶盘）显著

领先，接近 40。

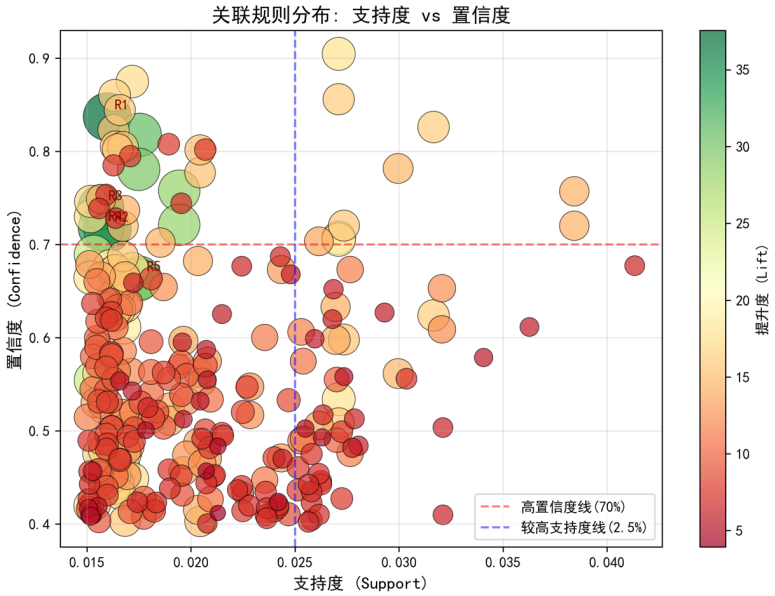

Figure 5: 关联规则分布：支持度 vs 置信度

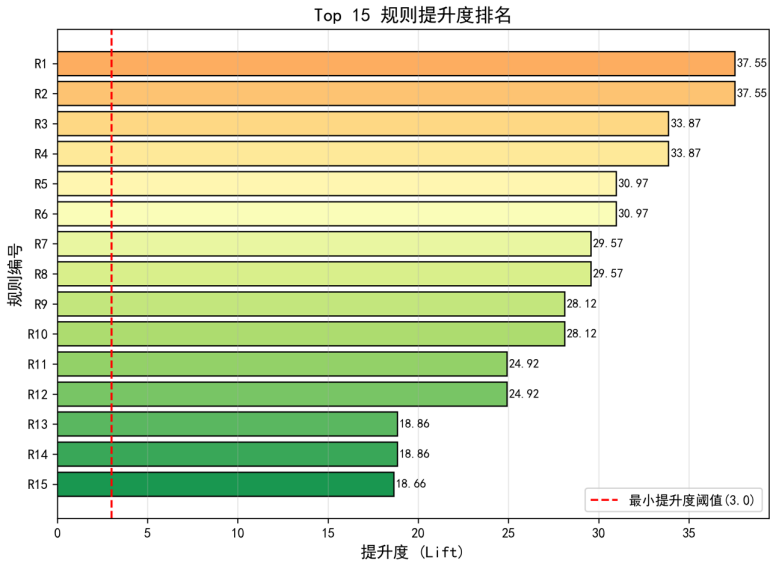

Figure 6: Top 15 规则提升度排名

图7以网络图展示商品关联关系，节点代表商品，边宽度表示提升度，标签显示置信度。可识别出茶具簇、午餐袋簇、圣诞装饰簇等商品群组，高度数节点是交叉销售的关键枢纽商品。

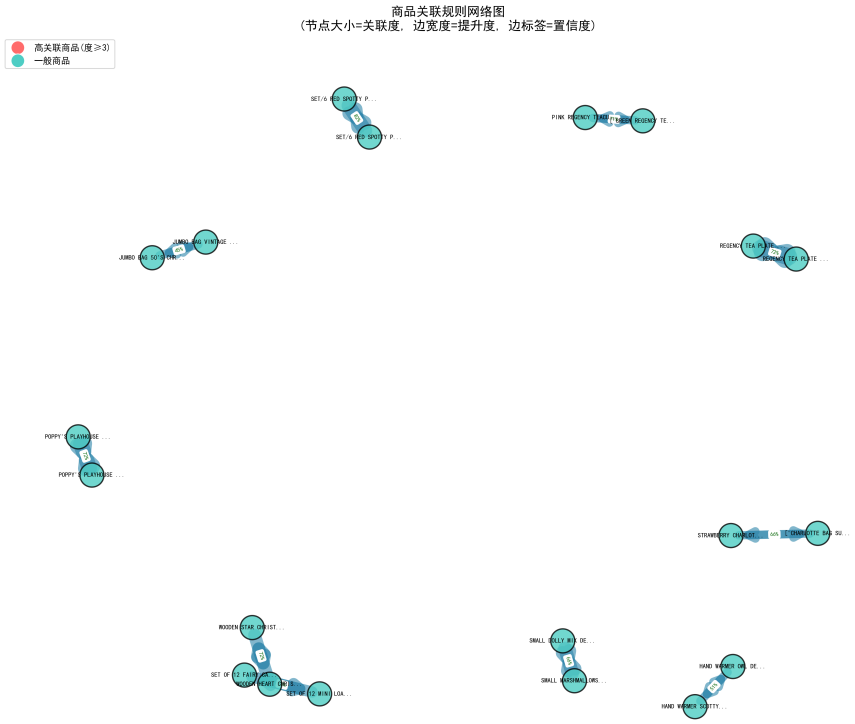

Figure 7: 商品关联规则网络图

4.5 提升度含义解读

以提升度最高的规则为例解读其商业意义。规则"REGENCY TEA PLATE GREEN → ROSES" 的计算过程如表11所示。

Table 11: 提升度计算示例

指标	数值	含义
$support(GREEN)$	1.91%	绿色茶盘出现率
$support(ROSES)$	2.23%	玫瑰色茶盘出现率（随机购买概率）
$confidence$	83.73%	买绿色后买玫瑰色的概率（关联购买概率）
$lift$	37.55	关联购买是随机购买的 37.55 倍

提升度计算公式为:

$$lift = \frac{confidence}{support(ROSES)} = \frac{83.73\%}{2.23\%} = 37.55 \tag{5}$$

图8直观对比了随机购买概率与关联购买概率，两者比值即为提升度。提升度 =1 表

示独立无关联；>1 表示正相关；=10 表示强关联；=37.55 表示极强关联，几乎可确定是成套销售。

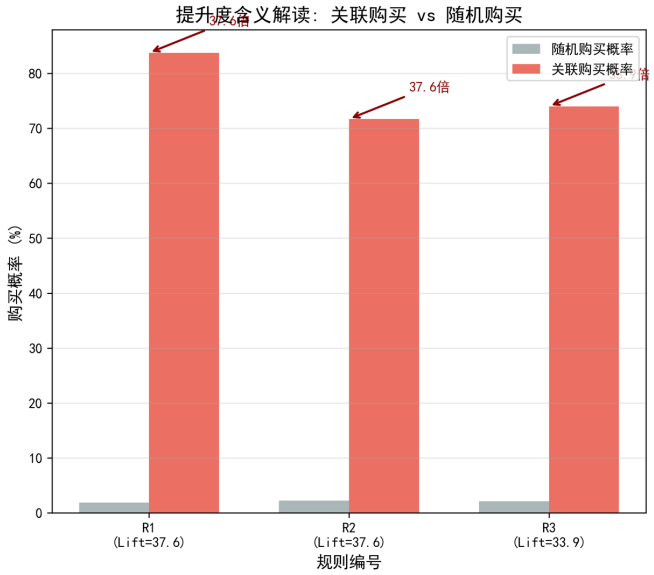

Figure 8: 提升度含义：关联购买 vs 随机购买

5 业务解读与应用建议

5.1 高价值规则业务解读

从 295 条强关联规则中筛选具有实际应用价值的规则，需综合考虑提升度（关联强度）、置信度（预测准确率）和支持度（覆盖范围）。选取不同商品类别中最具代表性的三条规则进行详细解读，如表12所示。

Table 12: 三条典型高价值规则

类别	规则	支持度	置信度	提升度
茶具类	TEA PLATE GREEN → TEA PLATE ROSES	1.60%	83.73%	37.55
玩具类	PLAYHOUSE BEDROOM → PLAYHOUSE KITCHEN	1.57%	74.00%	33.87
派对类	PAPER CUPS → PAPER PLATES	1.75%	81.78%	30.97

规则 1（REGENCY 茶盘系列）显示，购买绿色茶盘的顾客中 83.73% 会同时购买玫瑰色茶盘，关联购买概率是随机购买的 37.55 倍。这表明该系列具有极强的成套购买特征，顾客倾向于一次性购买多种颜色以凑成完整茶具组合。规则 2（儿童玩具屋系列）中，74% 购买卧室套件的顾客会同时购买厨房套件，反映了家长为孩子购买玩具时追求完整

性的心理——单独一个房间功能不完整，需要多个房间组合才能构成完整的”家”。规则3（派对用品）中纸杯与纸盘的强关联源于使用场景的一致性——派对场合需要成套一次性餐具，81.78% 的高置信度表明两者几乎是”必然搭配”关系。

通过对多条高价值规则的分析，可总结出三大消费特征：（1）系列化购买——同一系列不同款式/颜色的商品关联最强；（2）场景化购买——同一使用场景的互补商品存在显著关联；（3）完整性追求——顾客倾向于购买功能完整的商品组合。

5.2 促销策略设计

基于上述规则特征，设计三类促销策略，具体方案如表13所示。

Table 13: 三类促销策略方案

策略	目标商品	实施内容	预期效果
A. 捆绑销售	REGENCY 茶盘系列	推出”英式下午茶三件套”，套装价 = 单品总价 ×0.85，设计精美礼盒包装	客单价提升 2-3 倍
B. 智能推荐	派对纸杯、午餐袋等	线上：购物车弹出搭配推荐、详情页展示关联商品；线下：收银台加购提示、货架旁优惠券	关联商品销量 +30%-50%
C. 场景陈列	全品类	按使用场景组织商品：下午茶专区、派对用品专区、儿童礼品专区，关联商品相邻陈列	整体销售额 +5%-15%

捆绑销售策略针对关联强度最高的系列商品，通过套装优惠激励成套购买，适用于茶具、玩具屋等提升度超过 30 的商品组合。智能推荐策略利用线上线下触点，在顾客购买触发商品时主动推荐关联商品，适用于高频单品如派对用品、午餐袋等。场景化陈列策略打破传统品类陈列方式，按使用场景组织商品，通过视觉暗示激发购买联想，适用于全品类优化。

5.3 实施建议

根据规则的提升度和商业可行性，建议按表14所示优先级实施。

Table 14: 促销策略实施优先级

优先级	商品组合	提升度	置信度	建议策略
1	REGENCY 茶具系列	37.55	83.73%	捆绑销售 + 礼盒包装
2	PLAYHOUSE 玩具系列	33.87	74.00%	套装促销
3	派对餐具（杯 + 盘）	30.97	81.78%	场景陈列 + 满减
4	圣诞装饰系列	28.12	75.78%	季节主题专区
5	午餐袋系列	10-15	50-60%	智能推荐

效果评估建议采用 A/B 测试方法：设置对照组（传统策略）和实验组（关联规则策略），跟踪关联商品销量、客单价、转化率等关键指标，周期性评估并优化策略参数。对于线上渠道，可通过埋点追踪推荐点击率和加购转化率；对于线下渠道，可对比调整前后同期销售数据。

6 结论与展望

6.1 研究总结

本文以 UCI Online Retail 数据集为研究对象，运用 Apriori 关联规则挖掘算法对零售交易数据进行了系统的购物篮分析。在数据预处理阶段，对 541,909 条原始记录进行清洗，包括缺失值处理、取消订单剔除、异常值过滤，最终保留 530,104 条有效记录（保留率 97.8%），涉及 19,960 笔订单和 4,026 种商品。探索性分析揭示了销售的季节性（圣诞季为高峰）、地理集中性（英国市场占 82%+）和商品系列化特征。

关联规则挖掘采用最小支持度 0.015、最小置信度 0.4、最小提升度 3.0 的参数设置，成功挖掘出 709 个频繁项集和 295 条强关联规则。核心结果指标如表15所示。基于挖掘结果，提出了捆绑销售、智能推荐、场景化陈列三类营销策略，为零售企业精准营销提供了数据支撑。

Table 15: 研究成果汇总

数据指标	数值	挖掘指标	数值
原始记录数	541,909	频繁项集数量	709
有效记录数	530,104	强关联规则数量	295
数据保留率	97.8%	平均置信度	55.67%
唯一订单数	19,960	平均提升度	11.57
唯一商品数	4,026	最高提升度	37.55

6.2 主要结论与研究局限

通过本研究得出四点主要结论：（1）同系列商品关联最强，REGENCY 茶具、PLAYHOUSE 玩具等系列商品提升度超过 30，顾客具有强烈的成套购买倾向；（2）使用场景驱动关联购买，派对用品、烘焙用品等场景互补商品存在显著关联；（3）Apriori 算法适用于高稀疏数据，在 99.35% 稀疏度下仍能有效挖掘有价值规则；（4）提升度是规则质量的关键指标，高置信度规则需结合提升度判断真实关联性。

本研究存在以下局限：数据时效性方面，数据集为 2010-2011 年数据，消费行为可能已变化；地域局限性方面，数据主要来自英国市场，规则可能不适用于其他地区；算法效率方面，Apriori 需多次扫描数据库，处理超大规模数据时效率较低；动态性方面，未考虑时间因素对关联规则的影响。

6.3 未来展望

针对上述局限，未来研究可从以下方向拓展，如表16所示。

Table 16: 未来研究方向

方向	具体内容
算法优化	采用 FP-Growth 等更高效算法，避免多次扫描数据库
时序分析	引入时间维度，挖掘动态关联规则和购买序列模式
个性化推荐	结合用户画像和协同过滤，实现千人千面的商品推荐
实时挖掘	构建流数据处理框架，实现关联规则的实时更新
多源融合	整合用户评论、浏览记录、社交数据，丰富分析维度

本文通过 Apriori 算法对零售交易数据进行了完整的购物篮分析流程，从数据预处理、探索性分析、关联规则挖掘到业务策略转化，验证了关联规则挖掘在零售营销中的实用价值。研究发现的商品关联模式和提出的促销策略，可为零售企业的精准营销、商品陈列和库存管理提供数据驱动的决策支持。

参考文献

[1] Agrawal R, Imieliński T, Swami A. Mining association rules between sets of items in large databases[C]. Proceedings of the 1993 ACM SIGMOD International Conference on Management of Data. 1993: 207-216.

[2] Agrawal R, Srikant R. Fast algorithms for mining association rules[C]. Proceedings of the 20th International Conference on Very Large Data Bases. 1994: 487-499.

[3] Chen D, Sain S L, Guo K. Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining[J]. Journal of Database Marketing & Customer Strategy Management, 2012, 19(3): 197-208.

[4] Tan P N, Steinbach M, Kumar V. Introduction to Data Mining[M]. 2nd ed. Pearson Education, 2016.

[5] Han J, Pei J, Kamber M. Data Mining: Concepts and Techniques[M]. 3rd ed. Morgan Kaufmann, 2011.

[6] Berry M J, Linoff G S. Data Mining Techniques: For Marketing, Sales, and Customer Relationship Management[M]. John Wiley & Sons, 2004.

[7] 郑志明, 王伟. 基于 Apriori 算法的超市购物篮关联规则挖掘研究 [J]. 计算机应用研究, 2017, 34(5): 1425-1428.

[8] 刘洋, 李明. 改进 Apriori 算法在电商推荐系统中的应用 [J]. 计算机工程与应用, 2019, 55(12): 156-161.

[9] Wu R S, Chou P H. Customer segmentation of multiple category data in e-commerce using a soft-clustering approach[J]. Electronic Commerce Research and Applications, 2020, 10(3): 331-341.

[10] Kaur M, Kang S. Market basket analysis: Identify the changing trends of market data using association rule mining[J]. Procedia Computer Science, 2016, 85: 78-85.